

DE 143,7 MILLIONS DE PARAMÈTRES À 1 893 POIDS

Trajectoire expérimentale vers un diagnostic MCSA compact, événementiel et compatible MCU

Ce rapport met en perspective trois étapes de réduction successives : les grands réseaux profonds de la littérature, le modèle récurrent compact issu du travail MCSA, puis le SNN hard-forward actuel. Il sépare volontairement la taille du modèle, le nombre de calculs, la mémoire et l'énergie estimée.

75 900 x

moins de paramètres que VGG-19

1,9 x

moins de poids que le GRU

42,5 x

moins de propagations pondérées

Résultat central : le progrès le plus important ne vient pas d'une simple compression. Il vient d'une meilleure représentation physique du signal, puis d'un changement de nature du calcul. Le SNN ne multiplie plus des matrices denses à chaque pas. Il ne propage des poids que lorsqu'un événement utile apparaît.

Chiffres de référence

Étape	Architecture	Paramètres	Accuracy	Résultat principal
Littérature	VGG-19	143,7 M	99,4 %	Très haute précision, coût GPU
Papier MCSA	LSTM h=32	4 773	88,0 %	19,1 KB float32
Expérience SpikyPanda	GRU h=32	3 621	91,0 % test	364/400
Expérience SpikyPanda	SNN 32+5 LIF	1 893	78,5 % test	314/400, split groupé

Note terminologique : dans les références du papier MCSA, les modèles à plusieurs millions de paramètres sont des CNN profonds, notamment VGG-19 et NASNet-Mobile. Le MLP explicitement évalué est au contraire un petit modèle de 773 paramètres qui atteint 67,0 %. Le rapport utilise donc l'expression exacte **grands réseaux profonds**.

Document de synthèse technique | SpikyPanda | 27 août 2026

1. Pourquoi cette comparaison est significative

Une accuracy élevée ne dit rien, à elle seule, sur la possibilité d'embarquer le modèle. Un réseau de 143,7 millions de paramètres peut atteindre 99,4 %, mais il représente environ 574,8 MB de poids en float32 et suppose un environnement GPU. À l'opposé, une solution MCU doit tenir dans quelques kilo-octets et limiter les accès mémoire, les multiplications et les fonctions non linéaires.

La trajectoire étudiée répond donc à une question plus exigeante que la seule précision : **quelle quantité minimale de représentation et de calcul suffit pour extraire une information de sévérité réellement utile à partir du courant moteur ?**




Figure 1. Nombre de paramètres des architectures citées et des modèles SpikyPanda. L'échelle logarithmique est indispensable pour rendre visibles les modèles compacts.

Lecture correcte des facteurs de réduction

Comparaison	Rapport	Ce que cela signifie
VGG-19 / SNN	$143\,700\,000 / 1\,893 = 75\,909\,x$	Réduction du nombre de paramètres
NASNet-M / SNN	$5\,300\,000 / 1\,893 = 2\,800\,x$	Réduction du nombre de paramètres
LSTM MCSA / SNN	$4\,773 / 1\,893 = 2,52\,x$	Réduction du nombre de paramètres
GRU / SNN	$3\,621 / 1\,893 = 1,91\,x$	Réduction du nombre de paramètres
Calcul GRU / propagation SNN	$225\,280 / 5\,305 = 42,47\,x$	Réduction des opérations pondérées

Le facteur proche de 45 ne décrit pas la taille mémoire entre GRU et SNN. Il décrit la réduction des propagations pondérées par fenêtre. La taille des poids est, elle, divisée par 1,9.

2. Première rupture : comprendre le signal avant d'agrandir le réseau

Le papier MCSA part d'un constat physique. Une barre rotorique cassée crée des bandes latérales autour de la fréquence d'alimentation. Pour une fréquence réseau f et un glissement s , les composantes principales apparaissent autour de $f(1 - 2s)$ et $f(1 + 2s)$. Dans le domaine temporel, cela produit une modulation lente de l'amplitude, typiquement entre 2 et 6 Hz pour le banc étudié.

Fréquence de modulation approximative : $f_{\text{mod}} = 2 s f$

Les grands CNN appliqués au signal brut ou au spectrogramme disposent de millions de paramètres pour apprendre implicitement cette extraction. Le travail MCSA la rend explicite au moyen d'une enveloppe RMS sur un demi-cycle :

$\text{env}(t) = \text{racine}[(1/W) * \text{somme}(i=0..W-1) x(t+i)^2]$

Après suppression du transitoire, décimation vers 60 Hz et centrage par fenêtre, 256 échantillons haute fréquence sont remplacés par 64 valeurs d'enveloppe. La signature lente devient directement accessible au réseau récurrent.

Ablation rapportée dans le papier

Représentation	Accuracy	Échec ou gain observé
Signal brut, normalisation par trace, 64 pas	26,8 %	La normalisation efface la signature d'amplitude
Signal brut, normalisation globale, 256 pas	16,0 %	Gradient récurrent insuffisant sur la longue séquence
Enveloppe, min/max global	35,0 %	Le niveau de charge domine encore
Enveloppe centrée	88,0 %	La modulation utile devient visible

Le gain décisif n'est pas une couche supplémentaire. C'est la suppression d'une information inutile, la porteuse, et d'une variable parasite, la charge moyenne. Cette étape réduit le besoin de capacité de plusieurs ordres de grandeur.

Ce que montre le petit MLP

Le baseline FFT + MLP ne contient que 773 paramètres, donc moins que le SNN actuel, mais il atteint seulement 67,0 %. Cela prouve qu'un faible nombre de paramètres ne suffit pas. L'architecture doit être adaptée à la structure temporelle du phénomène. Le LSTM, le GRU et le SNN introduisent chacun une forme de mémoire que le petit MLP ne possède pas.

Résultat du papier MCSA

Le LSTM $h=32$ contient 4 773 paramètres, occupe 19,1 KB en float32 et atteint 88,0 % sur cinq niveaux de sévérité. La décision binaire sain/défectueux atteint 97,3 %. Ce résultat établit qu'une représentation physique explicite peut remplacer une grande partie de la capacité d'un réseau profond.

3. Deuxième rupture : du LSTM au GRU compact

Le GRU conserve une mémoire récurrente mais utilise trois groupes de poids au lieu des quatre portes du LSTM. Avec 3 entrées, 32 unités cachées et 5 sorties, le comptage exact est le suivant :

Entrée GRU : $3 \times 3 \times 32 = 288$ Récurrence GRU : $3 \times 32 \times 32 = 3\,072$ Biais GRU : $3 \times 32 = 96$
Sortie : $32 \times 5 + 5 = 165$ Total : 3 621 paramètres

Le meilleur checkpoint enregistré atteint 93,5 % en validation et 91,0 % sur 400 fenêtres de test, soit 364 classifications correctes. Les poids occupent exactement 14 484 octets en float32, soit 14,14 Kio.

Par rapport au LSTM du papier, le GRU réduit les paramètres de 24,1 % tout en passant de 88,0 % à 91,0 % sur le test observé. Cette évolution est encourageante, mais elle ne constitue pas une ablation contrôlée : le protocole et la version du pipeline ont également évolué.

Coût de calcul du GRU

Le runtime actuel calcule les trois portes du GRU et les cinq sorties à chacun des 64 pas temporels :

MAC par pas = $3 \times 32 \times (3 + 32) + 32 \times 5 = 3\,520$ MAC par fenêtre = $3\,520 \times 64 = 225\,280$

À ces opérations s'ajoutent 6 464 appels à sigmoid ou tanh. Sur MCU, ces fonctions peuvent coûter davantage qu'une multiplication-accumulation, sauf si elles sont remplacées par des tables ou des approximations dédiées.

Comparaison précision / compacité




Figure 2. La position d'un modèle ne doit être interprétée qu'avec son protocole expérimental. Les points de littérature, le GRU historique et le SNN groupé ne partagent pas tous le même découpage des acquisitions.

4. Troisième rupture : du calcul dense au calcul événementiel

Le SNN actuel ne remplace pas simplement les activations du GRU par des zéros et des uns. Il change l'interface entre le signal et le réseau. Neuf cellules sensorielles filtrent les trois courants autour de trois champs fréquentiels. Les croisements de phase et trois niveaux d'intensité produisent 54 ports de spikes binaires.

Topologie compilée : observation -> 9 cellules IIR -> 54 ports -> 32 LIF cachés -> 5 LIF de classe

Comptage exact des poids

Capteur vers hidden : $54 \times 32 = 1\,728$ Hidden vers classes : $32 \times 5 = 160$ Signal de fin vers classes : 5 Total : 1 893 poids entraînaibles

Le forward d'entraînement est strictement identique au forward LIF natif : seuil binaire, reset hard et aucune valeur fractionnaire transmise dans les liens. La dérivée surrogate intervient uniquement pendant le calcul du gradient. La loss est alignée sur le score réellement lu par le runtime :

$$\text{score}[c] = 2 \times \text{nombre_de_spikes}[c] + \text{membrane_finale}[c] / \text{seuil}[c]$$

Cette correction a fait passer le meilleur SNN hard-forward de 51,0 % à 78,5 % sur le test indépendant, tout en réduisant l'activité de 179,2 à 118,6 spikes neuronaux par fenêtre.

Calcul événementiel mesuré

Origine	Calcul	Opérations pondérées moyennes
Capteur -> 32 LIF	147,24 événements x 32	4 712 additions de poids
32 LIF -> 5 classes	117,64 spikes cachés x 5	588 additions de poids
Fin de fenêtre	1 événement x 5	5 additions de poids
Total réseau		environ 5 305 additions

Comme l'amplitude d'un spike vaut 1, la propagation peut se réduire à **membrane += poids**. Les multiplications restent nécessaires dans les neuf filtres IIR et dans la décroissance des membranes, mais elles ne sont plus répétées sur une matrice dense complète à chaque pas.

225 280 MAC pour le GRU contre environ 5 305 additions synaptiques pour le SNN : 42,5 fois moins de propagations pondérées par fenêtre.

5. Mémoire, CPU et énergie estimée

Mémoire des poids

Modèle	Paramètres	Poids float32	Poids int8	Observation
VGG-19	143,7 M	574,8 MB	143,7 MB	GPU dans la référence
NASNet-M	5,3 M	21,2 MB	5,3 MB	GPU dans la référence
CNN-LSTM	~100 k	~400 KB	~100 KB	Hybride profond
LSTM MCSA	4 773	19,1 KB	4,8 KB	Papier MCSA
GRU h=32	3 621	14,5 KB	3,6 KB	Checkpoint observé
SNN h=32	1 893	7,6 KB	1,9 KB	Poids seuls

Le déploiement SNN doit aussi stocker les coefficients des neuf filtres, les seuils, les constantes LIF et éventuellement les indices de routage. Une représentation spécialisée occuperait environ 8 à 9 Kio en float32. Un graphe générique sparse serait plutôt dans la zone 10 à 13 Kio. En int8, les indices peuvent coûter davantage que les poids. Il est donc essentiel de compiler les blocs denses sous forme de tableaux contigus.

Charge de calcul




Figure 3. Le capteur SNN ajoute environ 1 152 mises à jour de filtres biquad. En intégrant les filtres, les seuils, les LIF et le routage, la charge arithmétique utile est estimée entre 17 000 et 30 000 opérations simples par fenêtre.

Estimation MCU, modèle seul

Hypothèse illustrative	GRU	SNN spécialisé
Cycles par fenêtre	0,5 à 1,5 million	50 000 à 150 000
MCU 80 MHz	6,25 à 18,75 ms	0,63 à 1,88 ms
À 10 mW actifs	environ 60 à 190 µJ	environ 6 à 20 µJ
Rapport énergétique attendu	référence 1	environ 5 à 15 fois moins

Ces microjoules ne sont pas des mesures. Ils illustrent une plage plausible. Le ratio est plus robuste que la valeur absolue, qui dépend du MCU, du format numérique, de la mémoire et du compilateur.

6. Ce que l'estimation inclut, et ce qu'elle n'inclut pas

Le coût commun de l'enveloppe

Le GRU et le SNN consomment actuellement une enveloppe RMS déjà préparée. Sur le dispositif réel, cette enveloppe doit être calculée à partir de trois courants échantillonnés autour de 55,6 kHz. Sur une fenêtre de 1,066 s, cela représente près de 60 000 échantillons par phase, environ 178 000 carrés et 356 000 additions ou soustractions pour une RMS glissante simple.

Si cette étape est exécutée par le même MCU, elle devient un coût commun important et réduit l'avantage énergétique de bout en bout vers une estimation de 1,5 à 3 fois. Si l'enveloppe est fournie par le capteur, un DSP ou une chaîne d'acquisition existante, l'avantage du moteur neuronal seul reste plutôt de 5 à 15 fois.

La représentation logicielle compte

Le checkpoint SNN mesure environ 13,5 ms par fenêtre dans le navigateur. Ce temps ne reflète pas le potentiel MCU : le runtime TypeScript manipule un graphe dynamique, des objets d'événements, des canaux et des exponentielles génériques. Le gain attendu nécessite un noyau embarqué avec tableaux contigus, fanouts implicites, absence d'allocation par spike et coefficients de décroissance pré-calculés.

RAM de travail

Élément	GRU h=32	SNN 9 capteurs + 37 LIF
État principal	32 hidden + buffers de portes	9 états IIR + 37 membranes
RAM optimisée estimée	0,6 à 1,2 Kio	1 à 3 Kio
Risque principal	Buffers non réutilisés	Files d'événements et métadonnées de graphe

Le SNN gagne nettement sur les poids et le trafic mémoire, mais pas automatiquement sur la RAM. Un ordonnanceur événementiel trop générique peut consommer davantage d'état qu'un GRU compact.

Comparabilité des accuracies

Le GRU à 91,0 % utilise le dataset historique de fingerprint dcb578a0, avec 64 pas. Le SNN à 78,5 % utilise le dataset ec00f5c3, 128 pas à 120,110 Hz et un découpage groupé par acquisition. Ce dernier interdit qu'une acquisition, ou des fenêtres qui se recouvrent dans cette acquisition, apparaisse à la fois dans l'apprentissage et le test.

Il serait donc incorrect d'affirmer que le SNN perd exactement 12,5 points face au GRU à protocole identique. La prochaine comparaison scientifique doit entraîner le GRU h=32 sur ec00f5c3, avec le même train, la même validation et les mêmes 400 fenêtres indépendantes.

Robustesse ventilée par niveau de charge

Le jeu d'essai couvre huit niveaux de charge, de 12,5 % à 100 %. La matrice de confusion agrégée du checkpoint ne permet cependant pas d'établir à quelles charges les erreurs se produisent. Le papier ne doit donc pas attribuer les erreurs Healthy/BRB1 aux faibles charges sans rejouer l'inférence et rattacher chaque prédiction à son acquisition source.

Mesure à publier pour chaque charge	Rôle scientifique
Nombre de fenêtres et accuracy	Vérifier la représentativité et la stabilité globale
Rappel Healthy et rappel BRB1	Localiser la limite de détection du défaut léger
Erreurs Healthy vers BRB1 et BRB1 vers Healthy	Distinguer faux positifs et défauts manqués
Marge de classification et taux d'événements	Relier l'incertitude à la visibilité physique du signal

7. Interprétation R&D

La progression observée

Étape	Question résolue	Résultat obtenu
Grands réseaux profonds	Peut-on atteindre une accuracy très élevée ?	Oui, 96 à 99,4 %, avec 5,3 à 143,7 M paramètres
Prétraitement MCSA	Quelle information physique est réellement utile ?	Enveloppe lente 2 à 6 Hz, LSTM de 4 773 paramètres
GRU compact	Peut-on réduire la mémoire récurrente ?	3 621 paramètres, 91,0 % sur le test historique
SNN hard-forward	Peut-on remplacer le calcul dense par des événements ?	1 893 poids, 5 305 propagations, 78,5 % sur split groupé

Ce que le SNN démontre déjà

Le SNN actuel démontre qu'un réseau strictement binaire dans ses communications peut apprendre une classification à cinq niveaux sans pseudo-spikes dans le forward. Il atteint 78,5 % sur un test indépendant groupé avec 1 893 poids, 147,2 événements sensoriels et 118,6 spikes neuronaux par fenêtre. Son meilleur avantage n'est pas encore l'accuracy. C'est le passage d'un calcul dense systématique à une activité conditionnée par les événements du signal.

Ce qui reste à prouver

Validation	Mesure attendue
GRU sur split groupé	Accuracy, MAC, temps et énergie sur ec00f5c3
Noyau SNN MCU compact	Cycles exacts, flash, RAM, absence d'allocation
Quantification	Écart d'accuracy float32 contre int8/int16
Énergie physique	µJ par fenêtre mesurés au shunt ou avec un analyseur de puissance
Prétraitement complet	Séparer coût RMS commun, capteur ondulatoire et réseau
Robustesse par charge	Accuracy, rappels Healthy/BRB1, marge et taux d'événements pour chacune des huit charges

Conclusion : la trajectoire ne montre pas qu'un SNN est simplement un réseau plus petit. Elle montre qu'une compréhension physique du signal permet d'abord de supprimer des millions de paramètres, puis qu'une représentation événementielle permet de supprimer environ 42 fois les propagations pondérées restantes. Le résultat est une architecture crédible pour MCU, sous réserve de confirmer la mesure sur un noyau embarqué compact.

Références et provenance des chiffres

[1] G. Pelletier, *Envelope-Domain Preprocessing for Ultra-Compact LSTM-Based Broken Rotor Bar Severity Grading*, document local motor-current-mcsa-paper.pdf, 5 pages.

[2] Checkpoint GRU motor_current_best_val_93p5.json : GRU h=32, 3 621 paramètres, validation 93,5 %, test 91,0 % (364/400), fingerprint dcb578a0.

[3] Checkpoint SNN motor_current_snn_h32_5a83490c_best_val_82p5.json : 1 893 poids, validation 82,5 %, test 78,5 % (314/400), fingerprint ec00f5c3.

[4] Rapport expérimental local runtime-decoder-loss-experiment.md : protocole hard-forward, activité neuronale, identité avec le runtime natif et comparaison de loss.

[5] Les chiffres VGG-19, NASNet-Mobile et CNN-LSTM sont repris du tableau comparatif du papier MCSA, qui cite les travaux de Barrera-Llana et al. et Jakaria et al. Les protocoles publiés ne sont pas nécessairement identiques.